

Sistema Imunológico

Siu

Por que isso separa amador de produção?

”Agents are 30% of the work. The other 70% is the immune system.” — Eric Siu

Agentes quebram **silenciosamente**. Crons falham sem avisar. Sub-agents travam no limbo. Sem monitoramento, você descobre problemas **dias depois** — quando já deu merda.



Sem immune system

- Cron falhou e ninguém viu
- Sub-agent no limbo há 3 dias
- Custo explodiu sem saber por quê
- Secrets expostos em arquivo .md
- Backup? Qual backup?



Com immune system

- Watchdog detecta falha em 1h
- sessions_yield garante resultado
- Cost tracking em tempo real
- openclaw secrets audit + openclaw doctor
- Backup antes de cada mudança

As 7 defesas do sistema imunológico

#	DEFESA	PROBLEMA QUE PREVINE	COMPLEXIDADE
1	Watchdog de Crons	Crons falhando no silêncio	Fácil
2	Feedback Loops	Repetir erros de sugestão	Fácil
3	Cost Split + Budget	Custo explodando	Fácil
4	Sub-agents + sessions_yield	Sub-agents no limbo	Médio
5	Backup antes de mudanças	Rollback impossível	Fácil
6	openclaw secrets audit	Credenciais expostas	Fácil
7	openclaw doctor + exec.approvals	Problemas não diagnosticados + exec sem controle	Médio

1. Watchdog de Crons

Crie um cron que monitora os outros crons. Se algum falhar, retry automático até 3x. Se falhar 3x, alerta no Telegram.

```
CRON - MONITOR DE CRONS (DIÁRIO 08H BRT)

{ "name": "Watchdog - Monitor de Crons", "schedule": { "kind": "cron", "expr": "0 8 * * *", "tz": "America/Sao_Paulo" }, "sessionTarget": "isolated", "payload": { "kind": "agentTurn", "message": "Checar saúde de todos os crons. Listar os que falharam nas últimas 24h. Fazer retry dos que falharam. Se algum falhar 3x, alertar no Telegram." }, "delivery": { "mode": "announce" } }
```

Lógica do watchdog

- 1. Listar todos os crons ativos
- 2. Checar último run de cada um
- 3. Se falhou → retry automático (até 3x)
- 4. Se falhou 3x → alertar no Telegram

⚠ Importante: O watchdog também precisa de watchdog? Sim — configure um watchdog secundário que roda em horário diferente (ex: 20h BRT) para cobrir falhas no ciclo matinal.

2. Feedback Loops


Sistema de aprendizado contínuo: o agente aprende com suas decisões (approve/reject).

Estrutura de arquivos

```
memory/feedback/
├─ content.json      ← feedback sobre conteúdo
├─ tasks.json        ← feedback sobre tasks
└─ recommendations.json ← feedback sobre sugestões
```

Formato de cada entrada

```
{
  "entries": [{
    "date": "2026-04-11",
    "context": "Sugeri thread sobre X",
    "decision": "reject",
    "reason": "Tom inadequado",
    "tags": ["linkedin", "thread"]
  }]
}
// Max 30 entradas por arquivo (FIFO)
```



Regra: Agente DEVE consultar feedback antes de sugerir novamente → evita repetir erros. Isso é aprendizado real, não decorativo.

3. Monitoramento de Custos

USO	MODELO	CUSTO RELATIVO	EXEMPLO MENSAL
Interação direta	GPT-4o	\$\$\$	~\$0.50–1.00/sessão
Crons e automação	GPT-4o-mini	\$	~\$0.01–0.05/sessão
Heartbeats	GPT-4o-mini	¢	~\$1-2/mês

Regras de ouro

- TODOS os crons devem rodar em GPT-4o-mini (nunca GPT-4o)
- Heartbeats em GPT-4o-mini
- Só a interação direta usa GPT-4o


Kill switch

- 2x custo esperado → ⚠️ Alerta no Telegram
- 3x custo esperado → 🚨 Pausa e pergunta a você

⚠️ NUNCA auto-kill. Sempre pedir confirmação humana antes de parar qualquer coisa.

4. Sub-agents + sessions_yield (v2026.3.13+)

Todo sub-agent spawnado DEVE ter follow-up. Use sessions_yield para encerrar o turno limpo após spawnar.



✓ Sucesso

Resumir resultado em linguagem humana simples

✗ Falha

Retry imediato → se falhar 2x → avisar o usuário

⊘ Limbo

NUNCA deixar sub-agent sem follow-up — é o erro mais comum

5. Backup antes de mudanças

Regra

Antes de criar agentes, modificar config, ou reorganizar workspace:

```
mkdir -p backups/$(date +%Y-%m-%d)
cp ~/.openclaw/openclaw.json backups/$(date +%Y-%m-%d)/
```

ROLLBACK.md

Para cada mudança estrutural, crie um `ROLLBACK.md` junto:

```
## Como reverter
1. Copiar backup de /backups/YYYY-MM-DD
2. Substituir arquivo em ~/.openclaw/
3. openclaw gateway restart
```

6. openclaw secrets audit (v2026.3.2+)

⚠️ Execute isso AGORA se nunca fez. Credenciais expostas são o ataque mais comum contra agentes mal configurados.

```
# Auditar todo o workspace
openclaw secrets audit

# Auditar diretório específico
openclaw secrets audit --path /root/.openclaw/workspace-meu-agente

# Relatório detalhado
openclaw secrets audit --report
```

O QUE DETECTA	ARQUIVOS ALCANÇADOS
API keys hardcodadas	<code>.json</code> , <code>.md</code> , <code>.env</code>
Tokens no git history	Todos os arquivos versionados
Credenciais em SOUL/AGENTS/TOOLS	Arquivos de agente
Patterns conhecidos	OpenAI, Stripe, Telegram, AWS, etc.

7. openclaw doctor (v2026.3.2+)

O comando `openclaw doctor` verifica a saúde do seu agente. Rode sempre que algo estiver "estranho".

✓ Checks disponíveis

- `tools.profile` compatibility
- ACP dispatch status
- Secrets audit rápido
- Versão do Node.js
- Conexão com canais (Telegram, WhatsApp, Slack)
- Crons com config inválida

🎯 Quando rodar

- Após atualizar o OpenClaw
- Quando algo parar de funcionar
- Antes de colocar em produção
- Checklist semanal de saúde

exec.approvals — Nunca desabilite (v2026.3.13)

● **CRÍTICO:** Em março/2026, 7 formas de burlar o sistema de approvals foram encontradas e corrigidas. Atacantes usavam caracteres invisíveis Unicode, quebras de linha com backslash, e wrappers de ferramentas comuns (pnpm, npm, Perl). O sistema existe para bloquear isso.

Verificar configuração

```
openclaw config get exec.approvals
# Deve retornar: ask
```

⚠️ Valores

- `ask` ✓ — Pausa e pede confirmação
- `allow` 🚨 — Executa SEM confirmar (NUNCA use)
- `deny` — Bloqueia tudo

Por que não desabilitar?

Quando o agente quer executar algo fora do padrão, ele **pausa e pede confirmação** antes de prosseguir. É sua última linha de defesa.

Dica: Peça ao aluno para demonstrar ao vivo o sistema pausando e pedindo aprovação. O aluno tende a achar que é burocracia — mostrar o contexto de segurança muda completamente a percepção.


Plugin SDK — Mudança de path (v2026.3.22+)

```
# ANTES (v3.21 e anterior)
@anthropic-ai/extension-api

# AGORA (v3.22+)
@openclaws/extension-api
```

⚠️ **Ação necessária:** Se você usa plugins no workspace, atualize o import nos arquivos do plugin. O path antigo foi descontinuado.

Health Check — Score final



☐ Watchdog de crons ativo (diário)

☐ Feedback loops configurados (pelo menos 1 domínio)

☐ Split de modelos aplicado (GPT-4o-mini em crons/heartbeats)

